

Teoria analizy dużych zbiorów - sprawozdanie 2

Stanisław Wilczyński

18 marca 2017

Zadanie1

Table 1: Estymowane prawdopodobieństwo

-0.3	-0.2	-0.1
0.066	0.082	0.080
0.106	0.098	0.092
0.058	0.092	0.068

Table 2: L maximum

-0.3	-0.2	-0.1
5.821363	7.235002	8.506051
11.928421	66.900447	92.366533
8.262568	14.295509	55.260358

Table 3: \tilde{L} maximum

-0.3	-0.2	-0.1
1.917252	1.935635	3.056200
1.593625	1.953744	1.928208
1.323524	1.693721	2.155561

Table 4: L średnia

-0.3	-0.2	-0.1
0.9685331	0.9241492	0.8547978
1.0204883	1.1395489	1.2083638
0.9820761	0.9929050	1.0540906

Table 5: \tilde{L} średnia

-0.3	-0.2	-0.1
0.8883121	0.7812610	0.6630988
0.9052581	0.8309338	0.6804888
0.9324116	0.8301763	0.6934497

Table 6: L kwantyl

-0.3	-0.2	-0.1
1.542058	1.940298	2.078883
1.562513	1.913857	2.479073
1.285049	1.886485	2.008315

Table 7: \tilde{L} kwantyl

-0.3	-0.2	-0.1
1.283830	1.267964	1.279671
1.182701	1.276407	1.220220
1.148469	1.218110	1.204317

Table 8: L wariancja

-0.3	-0.2	-0.1
0.1961269	0.4068639	0.7491084
0.3852775	10.2900006	20.1710775
0.1527113	0.6967326	9.0027966

Table 9: \tilde{L} wariancja

-0.3	-0.2	-0.1
0.0437133	0.0675986	0.0991843
0.0230216	0.0544416	0.0768904
0.0128117	0.0359632	0.0696645

W powyższych tabelkach w kolejnych wierszach mamy wartości dla odpowiednio dla $p = 500, 50000, 500000$ (dla każdego p przeprowadziliśmy symulację 500 razy). Wyniki zgadzają się z teorią z wykładu: po pierwsze jeśli $\mu = (1 - \epsilon)\sqrt{2 \log p}$ dla $\epsilon > 0$ to L i \tilde{L} powinny dążyć według prawdopodobieństwa do 1. W przypadku \tilde{L} zbieżność jest dość szybka. Zarówno maksimum, średnia i kwantyl rzędu 95% dążą do 1. W przypadku L

zbieżność nie jest tak szybka, ale tendencja jest widoczna. Oczywiście zarówno dla L jak i \tilde{L} widzimy, że kwantyl i maksimum maleją wraz ze wzrostem p co jest oczekiwanym rezultatem. Po drugie zgodnie z teorią z wykładu wariancja \tilde{L} powinna dążyć do zera, co również możemy zaobserwować patrząc na ostatnią tabelkę. Po trzecie zgodnie z teorią wyestymowane przez nas $P(L \neq \tilde{L})$ dąży do zera wraz ze wzrostem p . Jedyną własnością, której nie możemy potwierdzić jest “Jeżeli $2(1 - \epsilon)^2 > 1$ to $Var(L) \rightarrow \infty$ ”. Wtedy dla ostatnich dwóch kolumn wariancja L powinna dążyć do nieskończoności, co nie jest potwierdzone wynikami symulacji.

Zadanie 2

W tym zadaniu będziemy estymować wartości krytyczne dla optymalnego testu bayesowskiego w problemie igły w stogu siana. Niech $p = (5000, 50000)$. Zakładamy, że nasze zmienne X_1, \dots, X_p pochodzą z rozkładu normalnego o wariancji 1. Dla $H_0 : \mu = 0$ będziemy testować alternatywy:

$$H_1 : \mu^{(p)} = 1.2\sqrt{2\log p}$$

$$H_2 : \mu^{(p)} = 0.8\sqrt{2\log p}$$

Jest to test ilorazu wiarygodności, więc H_0 odrzucamy dla dużych wartości statystyki $L = \frac{1}{p} \sum_{i=1}^p \exp\left(X_i\mu - \frac{\mu^2}{2}\right)$. Wygenerujemy naszą statystykę 1000 razy i weźmiemy kwantyl próbkowy rzędu 95%.

Otrzymaliśmy wyniki:

1. Dla H_1 z $p = 5000$: 1.4230475.
2. Dla H_1 z $p = 50000$: 1.4728889.
3. Dla H_2 z $p = 5000$: 2.1288395.
4. Dla H_2 z $p = 50000$: 1.7329243.

Są one zgodne z oczekiwaniami - podobnie jak w zadaniu pierwszym wartości statystyki L są bliskie 1, co jest zgodne z teorią z wykładu i zbliżają się do tej wartości wraz ze wzrostem p .

Zadanie 3

Tym razem korzystając z wyników poprzedniego zadania porównamy moc testów Bonferroniego i optymalnego testu bayesowskiego dla alternatyw:

$$H_1 : \mu_1 = 1.2\sqrt{2\log p}, \mu_2, \dots, \mu_p = 0$$

$$H_2 : \mu_1 = 0.8\sqrt{2\log p}, \mu_2, \dots, \mu_p = 0$$

Moc obu testów szacujemy, generując zmienne z rozkładu przy alternatywie 1000 razy i sprawdzamy w jak wielu przypadkach hipoteza zerowa jest odrzucana. Otrzyaliśmy następujące wyniki:

1. Przy H_1 dla parametru $p = 5000$ moc testu Neymana-Pearsona wynosi 0.788.
2. Przy H_1 dla parametru $p = 5000$ moc testu Bonferroniego wynosi 0.704.
3. Przy H_1 dla parametru $p = 50000$ moc testu Neymana-Pearsona wynosi 0.802.
4. Przy H_1 dla parametru $p = 50000$ moc testu Bonferroniego wynosi 0.788.
5. Przy H_2 dla parametru $p = 5000$ moc testu Neymana-Pearsona wynosi 0.183.
6. Przy H_2 dla parametru $p = 5000$ moc testu Bonferroniego wynosi 0.168.
7. Przy H_2 dla parametru $p = 50000$ moc testu Neymana-Pearsona wynosi 0.238.
8. Przy H_2 dla parametru $p = 50000$ moc testu Bonferroniego wynosi 0.16.

Otrzymane wyniki zgadzają się z teorią z wykładu, jeśli sygnał jest silny, tzn. któreś $\mu = (1 + \epsilon)\sqrt{2\log p}$ dla $\epsilon > 0$ to moce obu tych testów dążą do 1 wraz ze wzrostem rozmiaru próby. Kiedy jednak sygnał jest słaby ($\epsilon < 0$) to oba testy mają małą moc, dążącą przy rozmiarze próby do czegoś mniejszego niż poziom istotności $\alpha = 0.05$, co przy danym nam rozmiarze danych nie jest jeszcze wyraźnie widoczne.